

Microscopic-Image-Detection

Final 作業報告

組員：N26141850 林羿琪

N2614053 曾筠傑

NM6144046 林世璿

N26141931 呂建篁

N26141834 王介均

N26140901 吳佺倥

授課教授：詹寶珠 教授

114 年 12 月 30 日

目錄

目錄.....	ii
圖目錄	iii
表目錄	iii
一、資料分析與前處理	1
1.1 資料集分析	1
1.2 影像前處理與增強	2
1.2.1 Yolo 前處理.....	2
1.2.2 Yolo 資料增強.....	3
1.2.3 MIL 前處理.....	3
1.2.3 MIL 空間轉換.....	3
二、模型細節與訓練	4
2.1 模型細節	4
2.1.1 Yolo 模型選擇.....	4
2.1.2 Yolo 模型架構.....	4
2.1.3 MIL 模型架構.....	5
2.2 模型損失函數	6
2.2.1 Yolo 損失函數.....	6
2.2.2 MIL 損失函數.....	6
2.3 模型訓練與參數	6
三、實驗結果.....	7
3.1 結果分析	7
3.1.1 Yolo 結果分析	7
3.1.2 MIL 結果分析	9
3.1.3 模型比較.....	10
3.1.4 錯誤分析	11
3.1.5 自動化分流系統.....	12
四、結論	13
參考文獻	14

圖目錄

圖 1 Box Distribution	2
圖 2 Distribution of normalized bbox area	2
圖 3 MIL 前處理示意圖	3
圖 4 Yolo11 架構圖(改編自 :Khanam & Hussain (2024) [1])	5
圖 5 MIL 架構圖(改編自 :Kafle & Kanan [2])	5
圖 6 Training/Validation Loss/mAP curve(ours)	7
圖 7 Training/Validation Loss/mAP curve(TAs')	8
圖 8 Precision-Recall curve(ours)	8
圖 9 Precision-Recall curve(TAs')	8
圖 10 Yolo predict image(TAs')	9
圖 11 MIL 訓練結果	9
圖 12 MIL 可視化結果	10
圖 13 MIL 準確率	10
圖 14 Yolo confusion matrix(ours)	11
圖 15 Yolo confusion matrix(TAs')	12
圖 16 MIL confusion matrix	12
圖 17 Analysis_summary	13

表目錄

表 1 模型比較細節	10
------------------	----

一、資料分析與前處理

1.1 資料集分析

本資料集是顯微影像資料集，目標是對動物細胞做檢測，並辨識出陽性細胞，原先是以各小組利用 CVAT 標註軟體，將 raw data 進行標註，為了進行比較我們實作了兩個模型，但後續根據教授要求改由助教提供統一資料集進行測試與訓練，為此我們也有在 Yolo 上實踐，在之後的結果上也會一併放入說明。

- Yolo 資料集結構：
 - 資料切分：
 - CVAT(自己標註):將 786 張影像分為 80%訓練集、15%驗證集和 5%的測試集。
 - 助教版:400 張訓練集和 103 張測試集
 - 標註過濾：設定了 `annotated_only=True`，這表示程式會自動剔除那些「沒有畫框框」的圖片，確保模型只學習有標註的有效資訊
 - 異常細胞分佈分析：如圖 1 所示，這表示大部分的影像中，異常細胞的密度相對較低，但在少數影像擁有非常大量的細胞，揭示了資料集細胞分佈不均的特性，而在圖 2，解釋了為什麼我們後續的模型訓練為何需要使用高解析度圖片，因為絕大多數細胞的面積比例都集中在 0.000 到 0.005 之間，這代表了細胞目標非常微小，如果解析度太低，這些微小的細胞特徵會消失




圖 1 Box Distribution




圖 2 Distribution of normalized bbox area

- MIL 資料集結構：我們一共使用了 503 張陽性與 545 張陰性影像，並且會採取切塊策略 (Tiling Strategy)，將每張巨大的切片再切割成許多 128×128 像素的小方塊，後續再交由模型做判斷

1.2 影像前處理與增強

為了模型的參數需求，我們對影像資料做了以下的處理

1.2.1 Yolo 前處理

首先將所有影像調整成訓練所需的 yolo 格式，並且將圖片進行 Normalization，確保輸入模型裡圖片的比例是一致的，且因為此次資料集是偵測顯微鏡下的陽性細胞，根據

此資料集的特殊性，特別將圖片 resize 成 1024×1024 高解析度圖片，用來偵測較小的細胞

1.2.2 Yolo 資料增強

針對訓練資料分別進行了以下的資料增強處理，為了處理資料集在不同光源角度拍下的影像，我們會將圖片隨機進行色調與光影調整，並且還會將影像進行水平翻轉、縮放和平移，接著會用 mosaic=1.0，將 4 張不同的訓練圖片拼接成一張新的圖給模型進行練習，還會使用 erasing=0.4，代表有 40% 的機率隨機遮住圖片的一小塊區域，這模擬了細胞在圖片邊界的情境，逼模型去觀察物體的剩餘特徵來做決定。

1.2.3 MIL 前處理

首先我們應用了 Macenko 染色歸一化技術來消除不同影像之間的顏色差異，這能防止模型學到錯誤的特徵，誤把顏色深細胞當成陽性細胞，我們還開發了一個基於 HSV 飽和度的過濾器，一共捨棄了 6520 個不含資訊的背景方塊，讓模型的運算專注於相關的組織區域上




圖 3 MIL 前處理示意圖

1.2.3 MIL 空間轉換

為了讓電腦能正確分離標準化組織切片上的顏色，我們將影像從 RGB 色彩空間轉

換到光學密度 (OD) 空間，透過公式 $OD = -\log_{10}(I)$ 將 RGB 值轉換為光學密度空間，不同染劑顏色就變得線性可分，從而能夠進行去進行卷積。

二、模型細節與訓練

2.1 模型細節

2.1.1 Yolo 模型選擇

首先這次我們選擇 Yolo11 的 Extra-large 版本，Extra-large 版本擁有約 5690 萬個參數，我們還採用遷移學習，載入了官方在 COCO 資料集上的預訓練權重，其中模型內建的注意力機制 (C2PSA)，特別能捕捉複雜的特徵，十分符合這次的小目標資料集。

2.1.2 Yolo 模型架構

此模型架構分為 3 大類，分別是：

1. Backbone: 內有 C3k2 (Cross-Stage Partial Bottleneck) 模組，專門用來在不增加計算負擔的前提下增加網路深度，且 C2PSA 空間注意力機制能有效過濾環境雜訊，顯著提升複雜場景下的辨識穩定度，並且最後透過 SPPF (空間金字塔池化) 整合不同的資訊，確保模型對極小目標具備優異的偵測性
2. Neck: 提取完特徵後，模型需要把大範圍資訊和細節結合起來，透過 PAN-FPN 結構確保模型在定位物體座標能準確預測
3. Head: 模型會把找位置和確認類別兩件事拆開來處理，分開處理能顯著提高定位的精確度，並且輸出最終的方框與類別分數




圖 4 Yolo11 架構圖(改編自：Khanam & Hussain (2024) [1])

2.1.3 MIL 模型架構

我們會使用 ResNet50 特徵提取器，它不負責分類癌症，只負責將每一張 128×128 的小圖轉換成 2048 維特徵向量，再透過 ComplexDualAttentionMIL 架構使用精密的雙重注意力機制來衡量每個圖塊的權重，並找出最可疑的區域，如圖 5 所示。




圖 5 MIL 架構圖(改編自:Kafle & Kanan [2])

2.2 模型損失函數

2.2.1 Yolo 損失函數

在這次使用的 Yolo11 模型裡，我們使用複合損失函數進行優化，定位部分結合了 CIoU Loss 與 Distribution Focal Loss (DFL)，專門用來精確捕捉 1024×1024 解析度下的物體邊界與寬高比例，在分類的部分則採用 Varifocal Loss (VFL)，此外我們還使用 SGD 優化器，並配合 Warmup 與權重衰減機制，確保模型在訓練初期能穩定收斂，並在後期具備良好的泛化能力。

2.2.2 MIL 損失函數

在 MIL 模型中我們使用複合損失函數來糾正模型，Focal Loss 強迫模型專注於那些很難分類的樣本，Diversity Loss 則鼓勵模型不要只盯著某一種特徵看，而是多看不同的異常特徵，Sparsity Loss 基於異常細胞通常很少假設限制模型不要把太多區域都當成異常，Consistency Loss 則是確保模型在不同情況下的判斷邏輯是前後一致的。

2.3 模型訓練與參數

為了預防模型的過耦合，並且在有限的資料集下，訓練出良好的效果，我們採用了多種策略，像是資料增強、預訓練權重和 Early Stopping，確保最終使用的是泛化能力最強的模型，以下是我們的超參數設定。

- Yolo Hyperparameters
 - Batch Size: 0.7 (自動佔用 GPU 顯存 (VRAM) 的 70%)
 - Epochs: 3000
 - Input Size: 1024×1024
 - GPU: NVIDIA GeForce RTX 5090
 - Early Stopping: Patience=100(連續 100 輪的 Val Loss 沒有下降，終止訓練)
- MIL Hyperparameters

- Batch Size: 1 （之所以只能是1是因為每張圖片經過 Filter 之後可以使用的大小都不一樣，因此只能是 1）
- Epochs: 50
- Input Size: 128×128
- GPU: NVIDIA GeForce RTX 5080
- Early Stopping: Patience=15
- Learning Rate: $1e-4$

三、實驗結果

3.1 結果分析

3.1.1 Yolo 結果分析

Yolo 訓練的 loss 如圖 6、7，由圖可知訓練與驗證損失曲線在趨於平緩前有穩定下降趨勢，這表明模型正在有效學習具備泛化能力的特徵，而不僅僅是記住數據，而圖 8、9，則表示我們模型能定位異常細胞，並且在面對極小目標時，依然能在大約 85% 的情況下精準抓取且不產生太多誤報，圖 10 為預測圖。




圖 6 Training/Validation Loss/mAP curve(ours)




圖 7 Training/Validation Loss/mAP curve(TAs')




圖 8 Precision-Recall curve(ours)




圖 9 Precision-Recall curve(TAs')



圖 10 Yolo predict image(TAs)

3.1.2 MIL 結果分析

訓練的 Loss, Accuracy, AUC-ROC 如圖 11，由圖可知模型大概在第十個 epochs 之後準確率突然下降，這是因為模型有點趨於懶惰，當已經開始學習到某種程度的特徵，模型會開始嘗試學習別的區域的內容，因此會在第十個 epochs 特別下降，而圖 12，黃色/紅色區域代表高注意力 (High Attention)，模型認為這些地方含有「異常特徵」，深藍色區域代表低注意力 (Low Attention)，模型則是認為這些地方是背景或正常組織，最終我們預測出的準確率更是高達約 93%。




圖 11 MIL 訓練結果




圖 12 MIL 可視化結果




圖 13 MIL 準確率

3.1.3 模型比較

模型	主要任務	標註成本	優點	缺點
Yolo11	物件偵測	極高	能精確定位	人工成本高
Attention MIL	切片分類	極低	易訓練新數據	只能提供熱圖

表 1 模型比較細節

3.1.4 錯誤分析

根據圖 14、15 Yolo 與圖 16 MIL 的混淆矩陣錯誤案例，這可以顯現出我們成功抓取的 Positive 動物細胞個數，儘管模型表現優異，我們仍歸納出以下幾個問題點：

1. 目標極其微小：資料集分析顯示，大多數異常細胞僅佔影像面積的極小比例 (<0.005)，這對卷積神經網絡的特徵捕捉能力是巨大挑戰
2. 資料分佈不均：絕大多數影像細胞少於 50 個，但少數影像極度密集，代表模型可能在處理極端密集樣本時泛化能力不足
3. 染色變異：顯微影像本身存在的染色深淺不一，導致低對比度細胞容易被判定為正常細胞




圖 14 Yolo confusion matrix(ours)




圖 15 Yolo confusion matrix(TAS')




圖 16 MIL confusion matrix

3.1.5 自動化分流系統

此外依照這個作業，我們額外多做了一個輔助功能，希望未來可以用來輔助判決，由於影像解析度極高，我們採用了 SAHI (Slicing Aided Hyper Inference) 技術將大圖切片，並結合預訓練的 YOLO 模型進行推理，系統會掃描整張切片，找出所有潛在的異常

區域並繪製邊框，並將切片自動分類為三個風險等級(低、中、高)，判斷標準基於預先設定的「數量門檻」與「面積比例門檻」，分析完成後，系統會自動生成一份分析總結，詳列每張切片的量化指標與最終風險分類，可供使用者進行參考判斷。

slide_name	total_detections	abnormal_area_proportion	classification
0.png	0	0.0000	LOW_RISK
1.png	8	0.0157	HIGH_RISK
10.png	6	0.0055	HIGH_RISK
100.png	11	0.0111	HIGH_RISK
101.png	9	0.0022	HIGH_RISK
102.png	9	0.0148	HIGH_RISK
103.png	10	0.0029	HIGH_RISK
104.png	14	0.0051	HIGH_RISK
105.png	8	0.0061	HIGH_RISK
106.png	2	0.0007	MEDIUM_RISK
107.png	5	0.0044	HIGH_RISK
108.png	11	0.0085	HIGH_RISK
109.png	6	0.0041	HIGH_RISK
11.png	15	0.0164	HIGH_RISK
110.png	3	0.0013	MEDIUM_RISK

圖 17 Analysis_summary

四、結論

本次作業目的在於解決顯微鏡影像分析中長期存在的問題，即傳統動物細胞識別耗時且費力，透過深度學習技術的導入，我們的模型能成功自動檢測異常動物細胞系統，主要成果總結如下：

1. 雙模型架構的效能驗證：

- 全監督學習(Yolo11): 在物件偵測任務上，模型展現了優異的定位能力，雖然在低對比度與密集區域存在漏檢率，但其在精確定位上仍具一定價值，然而，此方法需要極高昂的標註成本。
- 弱監督學習(Attention MIL): 為解決標註成本問題，我們嘗試引入了基於注意力的多實例學習框架，該模型僅需切片級標籤即可訓練，MIL 大幅降低了標註門檻，但問題點在於它不會畫出方框，只能給出一個大概的「熱區」

2. 自動化分流系統的應用價值：該系統利用「總檢測數」與「異常區域比例」兩項量化指標，將切片自動分類為低、中、高風險指標，這套機制能協助使用者將注意力集中在高風險案例上，有效優化審查流程並提升診斷效率

參考文獻

- [1] R. Khanam and M. Hussain, "YOLOv11: An Overview of the Key Architectural Enhancements," *arXiv preprint arXiv:2410.17725*, Oct. 2024. [Online]. Available: <https://arxiv.org/abs/2410.17725>
- [2] K. Kafle and C. Kanan, "An analysis of visual question answering algorithms," *Computer Vision and Image Understanding*, vol. 163, pp. 3-22, 2017.